




“13:00-14:00 동안 클릭수 ”

→ GROUP BY 하면 안되나?

문제:

**데이터는 점진적으로 쌓이는데,
조회때마다 '처음부터' 계산한다**

해답:

**조회할때마다 계산하는 것이 아니라,
들어올때마다 조금씩 계산해두자**


스트림

**이벤트가 지속적으로 생산되니,
그것들을 스트리밍하여 집계하자**

새로운 문제:

집계 속도가 생산 속도에 항상 맞춰줄 수 없다

그것을 해결하기위해 이걸 하고싶다

1. 생산자와 소비자가 서로의 **속도를 모르게 하고싶다**
2. 소비자가 죽어도 이벤트를 잃어선 안된다
3. 생산자와 소비자의 속도를 독립적으로 늘이고 줄이고싶다

해답:

생산자와 소비자 사이에
durable한 저장소를 두자

**생산자와 소비자 사이에
durable한 저장소를 두자**

→ db?, s3?, redis?, mq(kafka)?

- db

write,read가 오래걸린다(스트리밍에 어울리지 않음)

여러 소비자가 읽게하는 것이 어려움(디비락은 무거워요)

리플레이가 어려움

- s3(object storage)

파일단위로 저장하는 오브젝트스토리지는 지연시간이 너무 큼

병렬소비 구현 자체가 아주 어려움

- 레디스


이벤트 지속 보관 비용이 큼

메시지를 보존해주지 않음 (캐싱 목적으로 만들어진거라 그럼. 넘치면 버림)

- 카프카

대량 디스크 저장에 특화되어있음 (스트리밍 목적)

여러 컨슈머가 자기속도로 읽을수있음



집계 서버 한 대로 이 트래픽을 감당할 수 있나?

집계를 어떻게 여러 서버에 나눌 것인가?

최근 M분이라는 시간 구간을 어떻게 정의할 것인가?

늦게 도착한 이벤트는 어느 구간에 넣을 것인가?

같은 클릭 이벤트가 두 번 처리되면 어떻게 할 것인가?

집계 서버가 죽으면 메모리에 있던 상태는 어떻게 복구할 것인가?

집계 결과를 DB에 쓰는 도중 장애가 나면 어떻게 할 것인가?

특정 광고로 트래픽이 몰리면 어떻게 할 것인가?

실시간 집계 결과가 틀렸는지 어떻게 검증할 것인가?

과거 데이터를 다시 계산해야 하면 어떻게 할 것인가?